

SEPA 通用视觉表征学习实验报告

V1、输入视野消融与 V2 阶段总结

报告日期：2026 年 9 月 16 日 | 实验设置：ImageNet-100, ViT-S/16, seed=0

1. 结论摘要

当前已测试的 SEPA V1 和 V2 尚未证明相对 I-JEPA 的方法优势。建议停止沿现有配置追加预训练，将本轮工作整理为负结果与机制消融。

这一判断来自三组主要证据：

- V1 的整体分类能力明显不足。** 100 轮预训练后，SEPA k=3 的正式验证集 Top-1 为 30.34%，I-JEPA 对照为 52.92%，相差 22.58 个百分点。V1 内部适度置换有收益，但没有弥补与基线的差距。
- 80×80 局部视野有代价，但不能据此把全部差距归咎于输入尺寸。** 在 I-JEPA 框架中，仅将 student 的预训练注意力限制在局部图块内，相同全局评估下 Top-1 从 52.92% 降至 46.90%；该实验的其他关键设计仍与 SEPA 不同。
- V2 仍未通过继续训练的筛选条件。** 25 轮时，在同一内部开发集上，V2-k3 为 46.92%，比 V2-k0 高 1.66 个百分点，但比纯 I-JEPA 低 2.94 个百分点。

以上足以支持当前路线的项目取舍；尚不足以证明所有包含空间置换的未来方法都无效。空间探针和稠密下游任务尚未完成，因此本报告也不声称 SEPA 的空间能力已经被证实或证伪。

2. 实验目标与统一协议

2.1 研究问题

SEPA 的假设是：在上下文既缺失、又发生空间置换时，预测原始正确位置上的 teacher 表征，能够促进可迁移的视觉结构学习。本轮围绕四个问题展开：适度置换是否优于不置换；SEPA 是否达到 I-JEPA 的表征水平；小块输入在推理与预训练中分别造成多大影响；保留全局 I-JEPA 训练后，局部置换分支是否带来额外收益。

2.2 数据与评估

项目	设置
数据集	ImageNet-100, 100 类; 126,684 条训练图像记录, 5,000 张正式验证图像
预训练	不使用类别标签; 随机种子固定为 0; batch size 为 64
编码器	ViT-S/16 规模: 12 层、384 维、6 个注意力头; patch 为 16×16 像素
主实验图像几何	图像经裁剪、缩放得到 240×240; 按 3×3 切为 9 个原生 80×80 图块, 无补边
训练长度	100 轮为 198,000 次更新; V2 筛选为 25 轮、49,500 次更新; 每轮最后一批为 28 张
冻结线性评估	encoder 不更新; 输出平均为 384 维图像特征, 再训练线性分类器
分类器设置	FP32; SGD, 学习率 0.005, 动量 0.9, 权重衰减 0; batch size 128, 训练 200 轮
评估预处理	中心正方形裁剪、双三次缩放至 240×240; 特征标准化统计仅来自分类器训练部分
辅助指标	kNN: 20 个邻居、温度 0.07; 特征有效秩: 固定 10,000 张训练图像上的诊断

Top-1 表示最高分预测正确的比例; Top-5 表示正确类别进入前五名的比例。kNN 不拟合线性分类器, 用于补充观察特征中的类别结构。有效秩反映特征方差分布的集中程度, 不是准确率, 也没有可单独判定方法成功或坍塌的阈值。本文准确率均以百分比报告, 差值均为百分点。

80×80 是图块大小, 16×16 才是 ViT 的 patch 大小。 每个图块含 25 个 patch, 整图含 225 个。局部评估依然使用整张图的 9 个图块, 只限制编码时的跨块信息交流, 再汇总全部图块特征; 并非只取一个 80×80 小块完成整图分类。

2.3 两套评估集合必须区分

V1、I-JEPA 100 轮基线及两轮视野消融, 均在 5,000 张正式验证图像上评估。V2 的 25 轮筛选采用训练集内部划分: 113,930 条记录拟合分类器, 12,668 条记录用于开发评估。划分前排除了 86 条标签冲突的重复图像记录, 其余相同内容图像按组划分, 避免跨组出现。

V2 内部开发集的图像参与过无标签预训练, 仅其类别标签未用于拟合分类器。 该结果用于同轮方案筛选, 不能与正式验证集准确率直接相减。本轮 V2 没有正式验证集最终成绩。

分类器配置此前通过训练集内部验证选定, 随后固定使用。所有主结果只来自一个 seed, 不报告跨 seed 均值、方差或统计显著性。

3. 各方案的关键设计

3.1 SEPA V1

将图像分为 3×3 图块，中心块始终可见且保持原位；从其余 8 块中隐藏 2 块，从剩余 6 个可见非中心块中选择 k 块随机重排。本轮比较 $k=0、3、6$ 。重排允许个别图块保持原位，因此 $k=3$ 表示选中 3 块参与重排，不表示每次必然移动 3 块。

Student 与 teacher 均独立编码各图块，使用共享的块内位置编码。每块的 25 个 patch token 先平均为一个图块表征；2 层、192 维 predictor 根据可见内容及其当前所在位置，预测两个隐藏块在原始正确位置上的 teacher 表征。语义损失采用归一化表征之间的平方距离；本轮关闭关系辅助损失。

V1 还包含一个整图注意力对照：允许可见 patch 跨图块交流，但保留 V1 的图块均值目标、小型 predictor 和损失。它属于 V1 内部对照，不能代表完整 I-JEPA 算法。

3.2 I-JEPA 对照与局部 student 消融

I-JEPA 对照基于官方实现，适配同一数据集、ViT-S/16、 240×240 输入、batch size 和 100 轮训练长度。Student 在可见上下文 patch 之间进行全局注意力；teacher 编码干净整图；6 层、384 维 predictor 完成多区域的 patch 级预测，使用 teacher 特征 LayerNorm 与 Smooth L1 损失。

局部 student 消融保留上述目标、predictor、全图位置编码及全局 teacher，只把 student 每一层的注意力限制在各自 80×80 图块内。它从头预训练，用来检验预训练阶段的视野限制。Teacher 参数由 student 的指数移动平均 (EMA) 更新，不独立反向传播。

3.3 SEPA V2

V2 从头训练，共享一套 encoder、predictor 和 EMA teacher，固定循环执行 3 个全局 I-JEPA 批次和 1 个局部 SEPA 批次，即 75% 全局、25% 局部。

局部分支保留每个可见图块的全部 25 个 patch token，不再先平均成单个图块表征；teacher 始终编码干净整图，预测目标为两个隐藏块的全部 50 个 patch token。局部 encoder 只使用共享块内位置编码，图块当前所在的全图位置在 predictor 处注入。V2-k0 与 V2-k3 的区别是局部分支是否执行受控置换。

每组先运行到第 25 轮，沿用 100 轮的学习率、权重衰减与 EMA 日程；这是一项中途筛选，不是压缩到 25 轮结束的完整训练日程。最终特征使用全局 student 提取。

3.4 比较的控制范围

V1 和 I-JEPA 匹配了数据、编码器规模、batch size 与训练轮数，但 predictor 容量、目标粒度、增强、优化细节和训练精度不同：V1 使用 FP32，I-JEPA 使用 BF16 混合精度；V1 含翻转与颜色扰动，I-JEPA 对照采用其裁剪增强。两者均使用 AdamW、峰值学习率 0.0001、2.5 轮预热及最终学习率 0.000001；V1 权重衰减固定 0.04，I-JEPA 从 0.04 调整到 0.4，EMA 调度也不同。

因此，V1 与 I-JEPA 的成绩反映整套方案的差异，不是等计算量的单因素实验，也不是论文 ImageNet-1K 数值复现。视野消融和 V2 的配对比较提供了更直接的局部证据。不同批次实验使用过不同型号 GPU，不能要求浮点训练轨迹完全相同。

4. 实验结果

4.1 V1：延长训练与置换强度

表 1：正式验证集 Top-1（%），冻结 student。

Encoder 预训练轮数	SEPA k=0	SEPA k=3	SEPA k=6	V1 整图对照
10	24.56	24.40	24.60	21.60
25	27.16	28.78	26.82	22.10
50	27.56	30.36	28.62	22.32
100	26.78	30.34	29.16	23.64

表 2：V1 第 100 轮正式验证集结果（%）。

方法	Top-1	Top-5	kNN
SEPA k=0	26.78	55.54	18.20
SEPA k=3	30.34	59.48	20.16
SEPA k=6	29.16	57.54	19.10
V1 整图对照	23.64	48.70	10.84

k=3 在 100 轮时比 k=0 高 3.56 个百分点，比 k=6 高 1.18 个百分点；在 25、50、100 轮均为三组置换强度中的最优值。适度置换在当前 V1 框架内有正向趋势。

但 k=3 的 Top-1 从 50 轮的 30.36% 到 100 轮的 30.34%，基本持平。Top-5 和 kNN 仍有提升，故不能断言所有指标均已停止改善；现有记录没有显示单纯增加训练时长足以解决其低分类准确率。

4.2 同规模 I-JEPA 基线与 teacher 选择

表 3：100 轮预训练，正式验证集结果（%）。

方法与评估分支	Top-1	Top-5	kNN
I-JEPA student	52.92	80.84	42.42
I-JEPA EMA teacher	52.86	80.74	42.36
SEPA k=0 student	26.78	55.54	18.20
SEPA k=0 EMA teacher	27.00	55.30	18.40
SEPA k=3 student	30.34	59.48	20.16
SEPA k=3 EMA teacher	30.60	59.68	20.30

同为 student，I-JEPA 比 SEPA k=3 高 22.58 个百分点；同为 teacher，差距为 22.26 个百分点。SEPA k=3 改用 teacher 仅提升 0.26 个百分点。

这表明 30% 左右不是该数据与编码器规模在当前评估下的表现上限，也不能把低分主要归因于选错 student / teacher 分支。V1 内部整图对照的 23.64% 同样不能用于否定全局注意力，因为它保留了 V1 的其余设计。

4.3 已训练模型：只改变推理视野

固定完成 100 轮全局预训练的 I-JEPA 权重，将推理从整图联合注意力改为 9 个 80×80 图块分别编码。每个 patch 保留其原来的全图位置编码，全部 225 个输出仍参与平均。各条件重新拟合相同配置的线性分类器。

表 4：正式验证集结果（%）。

分支与推理视野	Top-1	Top-5	kNN
Student, 全局 240	52.92	80.84	42.42
Student, 局部 80	51.54	79.84	38.88
Teacher, 全局 240	52.86	80.74	42.36
Teacher, 局部 80	51.50	80.00	39.04

Student 的 Top-1 下降 1.38 个百分点，teacher 下降 1.36 个百分点。已通过全局训练获得的权重，在局部推理下仍保留较强分类能力。该结论仅适用于这些权重和评估方式，不能据此断言从头使用局部视野训练同样没有明显损失。

4.4 从头训练：限制 student 的预训练视野

表 5：100 轮预训练，正式验证集结果（%）；最后一列为无单位诊断值。

Student 预训练视野 / 评估分支与视野	Top-1	Top-5	kNN	有效秩
全局 / student 全局 240	52.92	80.84	42.42	90.48
全局 / student 局部 80	51.54	79.84	38.88	72.22
局部 / student 全局 240	46.90	76.76	31.52	26.01
局部 / student 局部 80	46.70	76.22	31.18	25.00
局部 / teacher 全局 240	46.92	76.74	31.32	26.02
局部 / teacher 局部 80	46.44	76.36	30.96	25.00

在相同全局评估下，局部 student 预训练使 Top-1 下降 6.02 个百分点；在相同局部评估下，下降 4.84 个百分点。局部限制的训练代价明显大于前一实验仅改变推理方式时的下降。

局部预训练后的 student 恢复全局推理，只从 46.70% 提升到 46.90%。因此，训练完成后改变输入组织与注意力范围，不能立即补回全局预训练的能力。有效秩同步下降，说明特征方差更集中，但不能仅凭这一指标认定发生完全坍塌。

局部 I-JEPA 的 46.70% 仍高于 SEPA k=3 的 30.34%。这说明当前结果不支持“只要输入小块，就必然只能达到 30%”的判断。不过，两者还在 teacher 视野、位置编码、目标粒度、predictor 和优化设置上不同，不能将总差距机械拆分为各因素相加的贡献。

4.5 V2：全局与局部混合训练筛选

两组 V2 均完成 25 轮；各包含 37,125 个全局批次和 12,375 个局部批次。对照使用原 I-JEPA 第 25 轮权重，三组统一进行全局 student 评估。

表 6：12,668 条内部开发记录上的 25 轮结果（%）；此表不使用正式验证集。最后一列为无单位诊断值。

方法	Top-1	Top-5	kNN	有效秩
纯 I-JEPA	49.86	77.04	41.40	62.30
V2-k0：75% 全局 + 25% 局部，不置换	45.26	73.79	33.75	30.90
V2-k3：相同比例，局部分支置换	46.92	75.43	36.81	34.74

V2-k3 相对 V2-k0，Top-1 提升 1.66 个百分点，kNN 提升 3.06 个百分点。这与 V1 中观察到的适度置换收益方向一致，但仍只来自一个 seed。

相对纯 I-JEPA，V2-k0 的 Top-1 下降 4.59 个百分点，V2-k3 下降 2.94 个百分点。差值使用未四舍五入的原始准确率计算。V2-k3 的 kNN 也低 4.59 个百分点；有效秩为 34.74，低于基线的 62.30。

本轮未达到此前提出的“25 轮时与基线 Top-1 差距不超过 2 个百分点”的初步筛选条件。该条件是工程决策门槛，并非统计显著性检验。当前没有 V2 的 100 轮结果，也没有证据保证继续训练后能够反超。

5. 低准确率的原因分析

5.1 已有实验直接支持的判断

预训练阶段限制跨图块交流，会损害当前配方的分类表征。 局部 student 消融在匹配的全局评估下下降 6.02 个百分点，恢复全局推理也只带来很小改善。这支持把预训练视野作为一个实际影响因素。

适度置换本身不是本轮所有下降的来源。 V1 中 k=3 优于 k=0；V2 中 k3 同样优于匹配的 k0。两组实验均表现为“置换改善了其所属局部训练方案，但整个方案仍低于 I-JEPA”。

V2 当前的局部训练替换没有带来净分类收益。 在总更新次数相同的条件下，25% 的全局批次被局部任务替换；无论是否置换，最终均落后于纯全局基线。这是对当前任务和比例的结果，尚不能区分全局训练次数减少与局部目标干扰各自的影响。

补边及 teacher 分支选择不足以解释结果。 主实验直接使用 240→9×80 的无补边切分；切换 EMA teacher 仅带来很小分数变化。

5.2 合理但尚未被单独验证的机制

V1 在进入 predictor 前把每块 25 个 token 压成一个均值，可能丢失细粒度布局信息；局部 teacher 可能提供较弱的上下文语义目标；较小 predictor、归一化损失和优化配方也可能影响学习。这些均与当前结果相容，但尚未逐项完成配对消融，不能排列其确定的因果贡献。

V2 同时改变 teacher 视野、预测粒度、predictor 与训练任务组合。其结果表明这套组合尚未产生整体收益，不能反向证明其中每个修改都无效，也不能直接通过不同评估集合上的 V1 / V2 分数判断改进幅度。

6. 已完成检查与证据边界

训练前及实现验证覆盖了目标索引与置换映射、中心固定与隐藏块数量、隐藏像素隔离、teacher 无梯度、student 实际参数更新、局部编码与原生 80×80 参考计算的一致性，以及保存恢复后的训练状态。局部 student 与 V2 均通过各自的 15 项实现检查，I-JEPA 适配通过 11 项检查。

正式任务已达到记录的训练步数并完成相应分类与特征诊断；未记录到非有限损失或梯度。V2 的全局 / 局部更新比例、最后短批次和成对隐藏图块也经过检查。这些检查提高了结果可信度，但不等于证明不存在任何方法专属实现或配置问题。

本轮仍有以下限制：

- 仅一个 seed，无法判断跨随机初始化的波动与稳定性。不同分支或不同训练轮数不是独立 seed。
- V2 只完成 100 轮日程中的前 25 轮；内部开发结果不能替代最终正式验证结果。
- 统一线性分类器减少了评估配置差异，但训练 200 轮本身不证明每一种特征分布都已充分收敛；kNN 提供了方向一致的补充证据。
- 尚未完成相对位置、邻接、图块匹配、布局恢复等空间探针及其边界 / 位置先验捷径对照。Predictor 对位置变化有响应，不等于 encoder 学到了更好的空间表征。
- 尚无跨数据集迁移、检测、分割、低样本评估或关系辅助损失阶段的结果。不能作出这些能力已经提升或下降的结论。

7. 项目结论与处理建议

本轮结论是：当前 V1 整体方案的分类表现不足，当前 V2 混合方案未通过初步筛选；继续沿既有配置追加算力的依据不足。 V1 相对自身不置换对照的正收益，以及 V2 中同方向的置换收益，可以作为保留的实验发现，但不能写成 SEPA 已优于标准 JEPA，或已获得更好的空间表征。

建议不再直接延长 V1，也不自动把 V2 补到 100 轮或扩展更多 seed。保留本轮结果与必要模型，用于研究汇报和后续比较；旧版本中协议不同、已被正式结果替代的分数，不混入本报告主结论。

如果后续仍需围绕原始空间假设完成研究收尾，优先利用已有冻结权重进行空间探针，并同时设置 I-JEPA、k0、边界像素和位置先验对照。只有出现明确、可复核的空间优势，再讨论是否重新设计训练目标与投入新一轮预训练。这属于未来工作，本报告没有将其列为已完成实验。

附录：本报告采用的实验记录

实验批次	完成日期	纳入内容
SEPA V1 长训练与里程碑评估	2026-09-13	四个实验臂，10 / 25 / 50 / 100 轮冻结评估
I-JEPA 同规模基线	2026-09-14	100 轮 student / teacher，以及 SEPA teacher 对照
I-JEPA 冻结权重视野消融	2026-09-14	全局与局部推理比较
I-JEPA 局部 student 预训练	2026-09-14	100 轮及 student / teacher × 两种推理视野
SEPA V2 筛选	2026-09-15	两组 25 轮预训练及三组统一内部开发评估

数值来源为本轮保存的最终评估结果和里程碑汇总。报告使用固定轮数结果，不以历史小样本调试分数或训练过程中的临时状态代替正式结果。